

UNIVERSIDAD DEL VALLE DE GUATEMALA
FACULTAD DE INGENIERÍA
DEPARTAMENTO DE CIENCIAS DE LA COMPUTACIÓN
CC3066 DATA SCIENCE — SEMESTRE II, 2026

LABORATORIO 11: MLOps
(AVANCE — ALCANCE Y DIAGRAMA DEL FLUJO)

Observatorio de Turismo — Tikal y Flores (Petén)

Integrantes: Diego José López Campos — 23242
Luis González — 23353
Diego Rosales — 23258
Curso: CC3066 Data Science
Grupo: 3 — Tikal y Flores (Petén)
Fecha de entrega: 29 de octubre de 2026
Repositorio: DS-LAB11 (GitHub, privado)

Guatemala, Ciudad de Guatemala
2026

1. Qué estima el flujo

El observatorio necesita actualizar sus estimaciones de manera controlada y poder identificar qué datos, código y configuración produjeron los resultados que consulta un directivo. Este documento define el alcance del flujo que lo hará posible para el destino asignado al grupo: **Tikal y Flores (Petén)**.

Aspecto	Definición
Variable	Visitantes únicos del mes que declara la fuente de movilidad por telefonía móvil.
Unidad de medida	Personas.
Nivel de agregación	Subdestino por mes. Tres series: Isla De Flores, El Remate Y Alrededores Lago y Mundo Maya Aeropuerto.
Segmento	Visitantes extranjeros (todos los países excepto Guatemala). Ver la decisión D1 de la sección 8.
Meses que se estiman	Enero y febrero de 2026, que no tienen cobertura de telefonía.
Total de Petén	No se construye. Ver la decisión D2 de la sección 8.

2. Fuentes y columnas

Fuente	Archivo y hoja	Columnas usadas
Movilidad mensual	`BD_moviidad_mensual.xlsx`, hoja `Peten`	`destino`, `sub_grupo`, `anio`, `mes`, `pais`, `es_consecutivo`, `fecha`, `visitantes`, `dias_persona`, `permanencia_prom`
Migración	`Base_Migracion_2009-2026jun.xlsx`, hoja `Datos`	`Año`, `Mes cod`, `Tipo de Viajero` (solo Turista y Excursionista), `Viajero`

Cada ejecución registra la huella SHA-256 de ambos archivos. La base diaria de movilidad no se usa para construir la serie mensual y no se proyecta. Los datos son institucionales y de uso exclusivamente académico: no se incluyen en las imágenes de Docker ni en servicios externos, y el repositorio permanece privado.

Hechos verificados en los archivos

- La hoja `Peten` tiene 3,473 filas, tres subdestinos y **diez meses**: septiembre a diciembre de 2025 y marzo a agosto de 2026. **No existen enero ni febrero de 2026.**
- La clave `destino + fecha + pais + es_consecutivo` no tiene duplicados.
- Ocho filas tienen `visitantes = 0`, todas del segmento «menor a 1 día» y con `permanencia_prom` vacía. Otras ocho filas, distintas de las anteriores, tienen `pais` vacío.
- El 8.6 % de las filas de `visitantes` tiene decimales, porque las cifras expandidas no son conteos enteros.
- Guatemala es por mucho el primer país de la hoja: 2.9 millones en la suma de filas, frente a 57 mil de Estados Unidos, el segundo.
- La migración tiene 161,036 filas y 210 meses consecutivos, de enero de 2009 a junio de 2026. Hay una ruptura metodológica entre 2022 y 2023 que no afecta a este flujo, porque solo usa meses de 2025 y 2026.

3. Períodos de ajuste y evaluación

Uso	Períodos
Meses observados de movilidad	2025-09 a 2025-12 y 2026-03 a 2026-08
Meses a estimar	2026-01 y 2026-02
Meses evaluados	2025-12 y 2026-03 a 2026-06
Ajuste de cada mes evaluado	Todos los meses observados anteriores a ese mes, con un mínimo de 3

El factor de cada mes evaluado se calcula únicamente con meses observados anteriores, de modo que no se usa información futura. Julio y agosto de 2026 no se pueden evaluar porque la migración llega solo hasta junio de 2026. Octubre y noviembre de 2025 no se evalúan porque tendrían menos de tres meses de ajuste. **No se calcula error para enero y febrero de 2026**, porque no hay valores observados con los que compararlos.

4. Parámetros y supuestos

El factor de reparto del subdestino `s` se calcula con los meses de ajuste `T`, y la estimación de un mes `t` usa la migración de ese mes:

```
f[s]      = suma(V[s,t] para t en T) / suma(M[t] para t en T)
V_est[s,t] = f[s] * M[t]
```

`V` son los visitantes extranjeros de la hoja de movilidad y `M` las entradas de Turista más Excursionista de la migración. La migración aporta la forma estacional y el factor aporta la asignación a cada subdestino. Las referencias de comparación son el último valor observado y el promedio de los meses observados anteriores.

Parámetros de la configuración

Todo lo variable está en `config.yaml`: semilla 42, `factor_method = ratio_of_sums`, mínimo de entrenamiento de 3 meses, cobertura esperada de cada fuente, meses evaluados, rutas y umbrales. Al cargarse, el archivo se valida y rechaza claves desconocidas, meses mal formados y combinaciones incoherentes, como evaluar un mes sin migración. Los umbrales de aceptación se fijan antes de ver los resultados.

Supuestos

- **El factor se mantiene estable entre meses.** Con tres a nueve meses de ajuste, el efecto estacional propio del destino (por ejemplo, Semana Santa) no queda capturado. La validación mide cuánto error produce este supuesto.
- **La migración y la movilidad son medidas distintas.** La primera cuenta entradas al país y la segunda visitantes únicos del mes; el factor las relaciona de forma implícita.
- **No se compara un mes de 2025 con el mismo mes de 2026**, porque la fuente de movilidad no repite ningún mes entre ambos años.

5. Archivo que consume el tablero

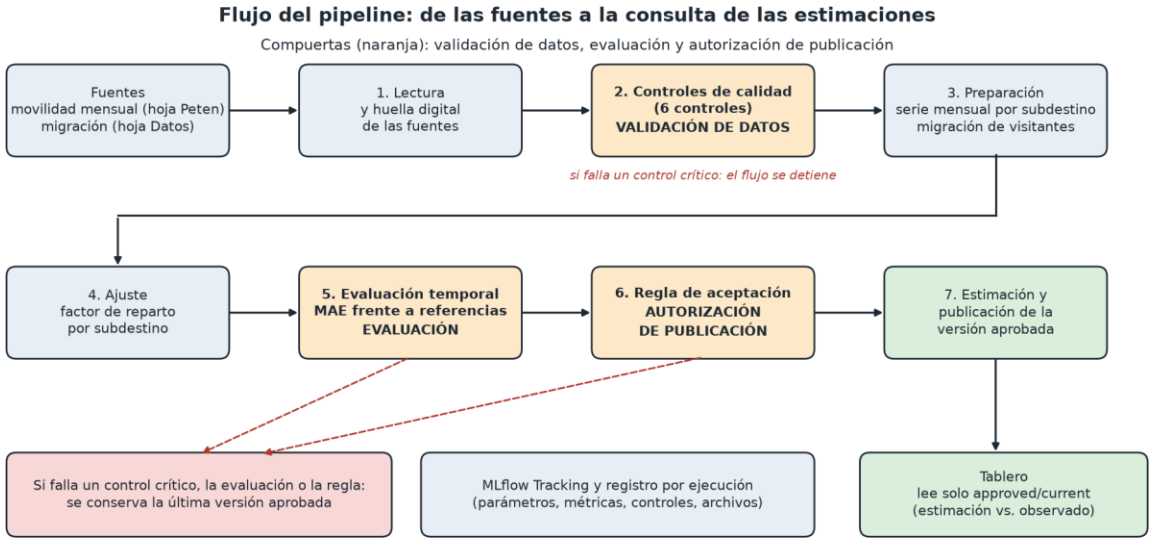
El tablero lee únicamente `approved/current/estimates.csv`, acompañado de `meta.json` con las métricas, los resultados de los controles y los períodos evaluados.

Columna	Contenido
`target`	Destino.

Columna	Contenido
`subdestination`	Subdestino.
`period`	Mes (AAAA-MM).
`value`	Visitantes. Vacío si no hay dato; nunca cero.
`unit`	Unidad de medida.
`kind`	`observed` o `estimated`.
`run_id`	Identificador de la ejecución.
`generated_at`	Fecha de generación.
`procedure_version`	Versión del procedimiento.

6. Diagrama del flujo

El diagrama va desde la lectura de las fuentes hasta la consulta de las estimaciones en el tablero. Las tres compuertas, resaltadas en naranja, son los puntos donde se valida, se evalúa y se autoriza.



Flujo del pipeline. Los recuadros naranja son las compuertas de validación, evaluación y autorización.

Compuerta	Paso	Qué decide
Validación de datos	2	Detiene el flujo si falla un control crítico.
Evaluación	5	Calcula el error contra las referencias, usando solo información anterior a cada mes.
Autorización de publicación	6	Aplica la regla de aceptación y decide si la versión reemplaza a la vigente.

Si cualquiera de las tres falla, no se modifica `approved/current` y el tablero sigue mostrando la última versión aprobada. Si todavía no existe ninguna, el tablero indica que las estimaciones no están disponibles.

7. Controles de calidad

Se implementan seis controles. Para cada uno se indica qué verifica, cuándo genera una advertencia y cuándo detiene la ejecución. Los períodos sin cobertura no se convierten en cero en ningún control.

Control	Qué verifica	Advertencia	Detiene
a) Columnas y tipos	Las columnas de la sección 2 y sus tipos.	Falta una columna no indispensable.	Falta una columna indispensable o su tipo no es compatible.
b) Fechas y cobertura	`fecha` coherente con `anio` y `mes`; meses observados contra los esperados en la configuración.	Enero y febrero de 2026 ausentes (esperado; no se rellenan).	Fecha inválida, o falta un mes que debía tener cobertura.
c) Unicidad	Clave `destino + fecha + pais + es_consecutivo`.	—	Hay duplicados.

Control	Qué verifica	Advertencia	Detiene
d) Valores faltantes	`pais` y `permanencia_prom` vacíos frente a `visitantes`.	Faltantes por debajo del umbral permitido.	Faltan `visitantes` o la migración del mes a estimar.
e) Valores y denominadores	`visitantes` negativo o no finito; migración del mes igual a cero.	Filas aisladas con `visitantes = 0`.	Valor negativo o no finito, o migración igual a cero en un mes usado.
f) Regla metodológica	La serie mensual sale de la hoja mensual y no de la diaria; no existe una fila que sume subdestinos; la estadía se calcula como días persona entre visitantes.	—	Se viola cualquiera de las tres reglas.

8. Decisiones, limitaciones y estado

Decisiones de diseño

- **D1. Solo visitantes extranjeros.** La migración cuenta entradas internacionales y la hoja `Peten` está dominada por visitantes guatemaltecos, que además traen factor de expansión. Aplicar un factor sobre la migración a esa mezcla no sería consistente. Los visitantes guatemaltecos se reportan aparte y no se estiman con este procedimiento. Se puede revertir vaciando la lista `exclude_countries` de la configuración.
- **D2. Sin total de Petén.** La guía de datos prohíbe sumar subdestinos, porque una misma persona aparece en varios, y el total no viene en los archivos. Las tres series se estiman y se presentan por separado.
- **D3. Pocos meses para validar.** Hay cinco meses evaluables. Una métrica calculada con tan pocos puntos es poco robusta, y el informe final la presentará con esa advertencia.
- **D4. Definición del factor.** Se usa la razón de sumas. Queda abierto compararla con la media de razones mensuales.

Las 14 pruebas del repositorio pasan. Cuando una etapa todavía no existe, la ejecución termina con código de salida 1 y un mensaje que indica el módulo faltante, en lugar de fallar con un error sin contexto.